

# Explorando alternativas no projeto de uma rede neural artificial para uma análise preditiva e forecasting sobre séries temporais econômicas no mercado de câmbio

Roberto Carlos Campos Torres<sup>1</sup>, Paulo Vitor de Campos Souza<sup>1,2</sup>

<sup>1</sup>Instituto de Gestão e Tecnologia da Informação- (IGTI)  
Rua Roma, 26 – 30.360-680 – Belo Horizonte – MG – Brasil

<sup>2</sup>Instituto de Comunicação e Design– Centro Universitário de Belo Horizonte  
Av. Professor Mário Werneck, 1685 – Estoril, 30.575-180 Belo Horizonte- MG- Brasil.

robertocortorres@hotmail.com, goldenpaul@informatica.esp.ufmg.br,  
pauloc@prof.unibh.br

**Abstract.** *The purpose of this paper was to evaluate the literature on predictive analysis in time series, to examine, to compare known types of analysis and to explore the proposition of a practical method to carry out such analysis on foreign exchange market data (FOREX) with the support of neural networks over the aim of constructing an algorithm or forecasting process capable of supporting corporate decision making regarding remittance of foreign exchange or purchase and sale of foreign currency using as a derivative example the Euro-Dollar pair. The objective is to demonstrate the validity of models built on neural networks for this purpose and its equivalence with other predictive models most used in the contemporary literature and for that, this paper uses hypothesis construction by comparing models through statistical analysis of variance (ANOVA). The analysis considers three neural networks with training algorithm based on Multilayer Perceptron (ROSENBLATT, 1961) and a comparative baseline algorithm widely used in machine learning, the Random Forest (BREIMAN, 2001). The study concludes by quantitatively and statistically, through ANOVA and Tukey's Test (HSU, 1996), asserting the equivalence of neural networks against other methods in the predictive analysis of financial-economic time series, using as base for testing the FOREX data between 2013 and 2016.*

**Resumo.** *O presente artigo buscou realizar um levantamento da literatura sobre análise preditiva em séries temporais, examinar, comparar conhecidos tipos de análise e explorar a proposição de um método prático para efetuar tais análises sobre dados do mercado de câmbio (FOREX) com o apoio de redes neurais com a pretensão de construir um algoritmo ou processo de previsão capaz de suportar a tomada a decisão corporativa quanto a remessa de divisas ou compra e venda de moeda estrangeira utilizando como exemplo derivativo o par Euro-Dólar. O objetivo é demonstrar a validade de modelos construídos sobre redes neurais com este fim e sua equivalência com outros modelos preditivos mais utilizados na literatura contemporânea e para tanto utiliza-se de construção de hipótese por comparação de modelos via análise estatística de variância (ANOVA). São considerados três redes neurais com algoritmo de treinamento baseado no Multilayer Perceptron (ROSENBLATT,*

1961) e um algoritmo de linha de base comparativa amplamente utilizado em aprendizado de máquina, o Random Forest (BREIMAN, 2001). O estudo conclui ao embasar quantitativa e estatisticamente, mediante ANOVA e Teste de Tukey (HSU, 1996), a assertividade da equivalência de redes neurais frente a outros métodos na análise preditiva de séries temporais financeiro-econômicas, utilizando-se como base para testes os dados do mercado de câmbio entre 2013 e 2016.

## 1. Introdução

A busca por modelos preditivos de Aprendizado de Máquina (*Machine Learning*) no emprego de predição de séries temporais financeiras tem trazido novos trabalhos e propostas com foco cada vez maior na eficiência do modelo. Não é difícil entender a necessidade de encontrar melhores métodos de *forecasting* e predição de comportamento de um ativo ou *commodities*. Variações nos mercados financeiros se somam às incertezas quanto ao investimento e como consequência, muitas corporações perdem grandes somas em conversão de moedas e divisas frente a mudança cambial em suas transações comerciais e envio de remessas à matriz. Os métodos estatísticos utilizados no passado por economistas não se mostram mais tão eficientes. Theofilatos et al. (2002) assevera que tais métodos falham ao capturar descontinuidades e não linearidades inerentes à alta complexidade de séries financeiras. Técnicas de aprendizado de máquina tem sido empregadas com relativo grau de sucesso na predição de comportamento em séries econômicas e financeiras.

Dada a importância no emprego desta tecnologia em um campo cercado de constantes variáveis e incertezas, neste texto analisar-se-á um modelo composto de análise técnica suportado por redes neurais onde serão comparados modelos de *Multilayer Perceptron* (MLP) (ROSENBLATT, 1961) e seus resultados a uma das técnicas mais bem-sucedidas neste campo dentro da literatura recente, o *Random Forest* (BREIMAN, 2001). Ainda que haja uma extensa literatura sobre predição em séries temporais e alguns autores apresentem um conjunto de tipos de redes neurais com tal aplicação (CHAPPELIER e GRUMBACH, 1994; ULBRICHT, 1995), o uso de redes neurais não tem sido amplamente explorado em todo seu contexto. Este estudo visa a obtenção de um modelo adequado utilizando-se de redes neurais na análise preditiva sobre séries temporais econômicas, contribuindo para suprir a deficiência atualmente constatada na literatura e consequentemente apresentar um modelo de solução prática de uma rede neural com seus parâmetros de melhor desempenho em uma base de dados do FOREX (*Foreign Exchange*) para a solução do problema proposto sobre séries financeiras. O enfoque neste estudo também se justifica por sua meta em contribuir com informações objetivas na temática do estudo e na construção do saber pela análise e comparação de motivos prós e contra o uso de redes neurais aplicados a modelos financeiros em especial destaque ao câmbio de compra e venda de pares de moedas estrangeiras. Visando a construção de hipóteses e solidificação das bases teóricas, esta análise explora e descreve um modelo bem como suas bases conceituais para posterior investigação da problemática na comunidade científica. Embora as análises do presente estudo se restrinjam ao mercado de câmbio em especial ao par *Euro-Dólar*, o material aqui apresentado não se limita apenas a tal instrumento, porém demonstrar-se-á uma base de análises futuras e comparativas entre outros pares e instrumentos de semelhantes

financeiras. Este artigo se divide da seguinte maneira: será apresentado o mercado financeiro de câmbio, em especial o FOREX (*Foreign Exchange*), o conceito de análises técnicas e fundamentalistas atualmente empregadas por analistas econômicos e em seguida fundamentar-se-ão as bases científicas na construção do modelo que permeará o cerne da presente pesquisa, posteriormente serão apresentados os instrumentos metodológicos empregados no artigo e por fim, nas últimas sessões se encerra apresentando a pesquisa e seus resultados.

## **2. Referencial teórico**

### **2.1 Conceitos econômicos e financeiros básicos**

Uma das grandes dificuldades dos analistas e economistas está na procura por ferramentas que possam prever com maior precisão as mudanças nos mercados cambiais incluindo movimentos financeiros e variações em *commodities*. Tal dificuldade em precisar os movimentos em ativos tem feito muitos economistas adotarem a perspectiva de hipótese de eficiência de mercado, que sugere que as variações de preços em mercados financeiros são independentes de movimentos passados e seguem padrões aleatórios (MALKIEL, 1985). Para efeitos desta pesquisa tal hipótese será desconsiderada, uma vez que se objetiva demonstrar que a previsibilidade de movimentos no mercado financeiro é possível e pode ser feita com certo grau de acurácia. Nas sessões seguintes são apresentados conceitos referentes ao mercado financeiro sobre o qual se construiu este estudo, instaurando-se bases da fundamentação teórica aplicada em sessões futuras.

### **2.2 FOREX (Foreign Exchange)**

O Mercado Internacional de Câmbio (FOREX) se constitui o maior mercado financeiro de troca de ativos do planeta, com mais de três trilhões de dólares sendo negociados diariamente. Seus instrumentos de negociação se constituem de pares de moedas ofertadas a todo instante, vinte e quatro horas por dia (com volume de negociação próximo a zero nos finais de semana). Além de instituições financeiras, qualquer pessoa pode atuar como um *trader* e negociar um par de moedas, por exemplo vender dólares e comprar euro, neste caso denominado compra no instrumento EURUSD. Existem taxas cobradas diferentemente dependendo do volume de compra e tipo de conta do negociador, os custos de transação. Para efeitos deste estudo serão apenas consideradas as variações sobre o instrumento EURUSD e não serão considerados margens de lucro ou diferentes tipos de negociação (KAUFMAN, 1987). Este mercado segue também a lei da oferta e procura, podendo interferir em preços de seus instrumentos, provocando altas, baixas e ou instabilidades momentâneas, além de ser influenciado por distintas variáveis externas e não intrínsecas ao dia a dia de negociação (*day trade*).

#### **2.2.1 Análise Fundamentalista e Técnica**

Os métodos utilizados entres os *traders* para realizar as compras e vendas de instrumentos em FOREX podem ser agrupados em análise técnica e fundamentalista (KAUFMAN, 1987). A análise fundamentalista é essencialmente influenciada por fatores macroeconômicos de oferta e procura, conforme sustenta Abu-Mostafa e Atiya (1996). Aqui incluem-se fatores econômicos de cada país envolvido no instrumento em

negociação, os índices econômicos divulgados no período de análise, balança comercial, entre outros elementos da econometria influenciadores da produção e modificadores de comportamento sobre investidores do par cambiado em questão. Como exemplo, mudanças climáticas podem influenciar agricultura e consequentemente interferir de forma negativa na balança comercial de um dos países envolvidos, implicando em uma diminuição no valor de um instrumento em detrimento ao seu par. Por outro lado, a análise técnica leva em conta apenas os fatores envolvidos nos processos da troca de posse do instrumento, sendo determinados exclusivamente pelos padrões observáveis no mercado, podendo ser calculados através de ferramentas técnicas sobre dados históricos. Tal característica torna a análise técnica muito interessante sobre o ponto de vista desta pesquisa uma vez que compartilha com o arcabouço ferramental utilizado na predição em problemáticas esperado por técnicas de aprendizado de máquina.

### **2.3 Métodos de Análise em Séries Temporais Financeiras**

Ainda que a análise fundamentalista forneça indicativos claros de tendências econômicas, modelos mais quantitativos como a análise técnica são preferidos ao tentar prever o comportamento de séries temporais financeiras. Em seguida, relaciona-se alguns destes. Entre alguns dos métodos mais empregados com sucesso no mercado de FOREX está a avaliação de tendências feita pela média de movimentação do mercado (MA). Consiste em detectar se um preço está acima ou abaixo de uma média de longa data sobre transações no mercado, indicando tendência de subida ou descida respectivamente. MA se destaca como um dos mais importantes indicadores de tendência momentânea de movimento de preços (ULLRICH et al., 2007). Outro método também utilizado na predição de séries financeiras se configura como a regressão linear, também utilizada no aprendizado de máquina, segue os princípios de encontrar a tendência do mercado (subir ou descer) pelo coeficiente angular da reta traçada pelo modelo sobre dados financeiros de movimentos anteriores (MONTGOMERY et al., 1990). Uma óbvia desvantagem dos métodos anteriores está no fato de serem reativos, ou apenas poderem apontar a tendência após já ter sido iniciada. Uma alternativa está em encarar os dados como variáveis contínuas, fazendo-se uso de distribuições condicionais linear-gaussianas. Em que cada nó tem uma distribuição gaussiana cuja média é uma função linear de seus pais (considerando uma sequência). Isto é conhecido como um modelo auto regressivo (AR) (BOX et al., 1994). Em séries financeiras um método adaptado deste último e muito utilizado em *quantitative trading* é o *autoregressive integrated moving average* (ARIMA). Através da modelagem como sistema linear. Os parâmetros são estimados usando dados históricos. Sobre estes parâmetros então calculados, pode-se realizar estimativas ou *forecasts* (MONTGOMERY et al., 1990).

Para efeito de simplicidade muitos modelos são construídos assumindo-se algumas condições que podem não ser verificadas nos valores diários transacionais de precificação em FOREX. A particularidade de serem os dados dimensionais linearmente independentes para preditores colunares não se configura como uma realidade para períodos muito curtos em séries financeiras – e é exatamente por esta particularidade que predições no *day trading* (compra e venda no mesmo dia) não são confiáveis (BERLINGER et al., 2015). Atualmente existe uma variedade grande de modelos empregando aprendizagem de máquina na predição de comportamento de séries

temporais financeiras de modo bem-sucedido pela comunidade científica. Entre algumas das técnicas se encontram o *Support Vector Machines* (SVM), *Random Forest*, e redes neurais. Dentre estes, *Random Forest* figura como um dos algoritmos de melhor desempenho na construção de modelos preditivos para o FOREX, com enfoque no EURUSD (THEOFILATOS et al., 2002). Dunis e Williams (2002) empregaram um modelo treinado sobre *Multilayer Perceptron* (MLP) demonstrando a eficácia deste método como predição de valores sobre o par Euro-Dólar. Em trabalhos posteriores a estes, novas predições envolvendo ainda outros algoritmos de aprendizado de máquina foram extensivamente empregados sobre o EURUSD em FOREX e, finalmente Dunis et al (2010) comparou *Higher Order Neural Networks*, *Psi Sigma Networks*, *Recurrent Networks* e MLP se mostrou muito superior aos demais modelos de redes neurais, e por esta razão, escolheu-se métodos MLP neste estudo para comparação com a linha de base (*benchmark*).

### 3. Metodologia

O estudo reúne características tanto qualitativas como quantitativas ao explorar referencial tratado por alguns autores e ao primar pela busca da criação de um procedimento ou método de análise preditivo fazendo-se uso de sistemática quantitativa na comparação dos dados sob o ponto de vista de várias técnicas apresentado o melhor resultado analisando-se o par cambial *Euro-Dólar* (EUR-USD). Este estudo recorre a uma análise quantitativa na busca de visão do resultado pelo positivismo que por sua vez prima pela objetividade, quantificando e classificando os dados coletados. Esta pesquisa em sua primeira parte será caracterizada pela exploração qualitativa (GIL, 2008) e descrição de alguns modelos ou técnicas de previsão (*forecasting*) de séries temporais econômicas, com ênfase ao FOREX, comparando-se desempenhos estudados e resultados registrados na literatura, configurando-lhe características exploratórias. Ainda que esta análise não seja de modo algum completa, se mostra suficiente como linha de base comparativa e a adoção dos métodos estudados e mesmo dos hiper-parâmetros da rede neural escolhidos na aplicação prática são justificados na sequência neste texto durante a apresentação da pesquisa. Tendo em vista o objetivo de elaboração metodológica que permita sistematização e posterior verificação sobre o objeto de análise sem introdução de subjetividade do pesquisador (SELLTIZ et al., 1965), em sua segunda parte, o presente estudo se concentrará em realizar uma análise quantitativa visando elaborar uma hipótese sobre o estudo mediante uma análise formal com deduções lógicas e estatísticas que a fundamentem (MARCONI e LAKATOS, 2007). Com tal intuito, faz-se uso de quatro técnicas estudadas em um laboratório de dados (três tipos diferentes de *Multilayer Perceptron*, posteriormente descritos, e um *Random Forest*), onde busca-se criar um método otimizado de predição da taxa cambial futura além de comparar resultados utilizando de software e linguagem R na busca da melhor assertividade do modelo preditivo considerando o par *Euro-Dólar*.

Apresenta-se na sessão de resultados uma formalização estatística descritiva e comparativa dos dados coletados no espaço amostral estudado (transações sobre o referido par no mercado de câmbio no período de janeiro de 2013 a dezembro de 2016) bem como realiza-se uma análise de variância (ANOVA) como metodologia estatística descritiva sobre os quatro métodos abordados, seus dados e resultados e tabula-se suas comparações com o fim de formular uma hipótese de equivalência do uso de redes

neurais frente a métodos eficazes em tais estudos, através do teste de hipóteses de Tukey (HSU, 1996; JOHNSON & WICHERN, 1998). A base de dados utilizada contém os valores das transações realizadas no FOREX sobre o par EURUSD durante 48 meses compreendidas no período de 2013 a 2016 (4 anos). Sobre este período é importante destacar a crise Europeia ocorrida no primeiro semestre de 2014, onde uma considerável queda no instrumento criou certos vieses sobre os dados coletados. Deste modo, o pesquisador caracterizou sua base de dados como contendo um período pré-crise europeia (2013), *in-crise* (2014) e pós-crise (2015-6). A escolha por este período de quatro anos se justifica na intenção de criar um modelo preditivo recente e resiliente, capaz de demonstrar que a utilização de redes neurais é tão eficiente ou talvez melhor que outros métodos de aprendizado de máquina mesmo em períodos de incertezas e mudanças fundamentalistas no cenário da econometria.

#### 4. Apresentação da pesquisa

A pesquisa realizada de cunho exploratório objetivou comparar métodos de predição usando-se redes neurais cujo desempenho foi analisado frente a modelos de aprendizado de máquina bem-sucedidos já registrados na literatura. Fazendo-se uso do algoritmo *Random Forest* como linha de base de comparação (*benchmark*), usando-se o algoritmo *rf* da biblioteca *randomForest* do CRAN no R Studio com parâmetros default e outros três modelos de MLP (*Multilayer Perceptron*) também foram empregados com distintos hiper-parâmetros. Os três algoritmos de redes neurais utilizados são: *backpropagation* tradicional, *resilient backpropagation with weight backtracking* e outra variação de *resilient backpropagation with weight backtracking* com autoconfiguração da taxa de aprendizado (o próprio algoritmo buscava a taxa mais adequada) com menor gradiente absoluto (RIEDMILLER & BRAUN, 1993; RIEDMILLER, 1994). A Tabela 1 descreve os detalhes.

**Tabela 1. Redes neurais comparadas no estudo (algoritmos definidos na biblioteca neuralnet - CRAN)**

	Backpropagation Tradicional	Backpropagation com pesos e backtracking (ativ = tanh)	Backpropagation com auto calc. taxa aprendizado
Camadas Ocultas	1	1	2
Algoritmo (nome na API)	<i>backprop</i>	<i>rprop+</i>	<i>sag</i>
Função de Ativação	Logística	Tangente hiperbólica	Logística
Função de Erro	Quadrática	Quadrática	Quadrática
<i>Backtracking</i> sobre Pesos	Não	Sim	Sim
Taxa de Aprendizagem	0.01	Auto calculada	Auto calculada
Neurônios por Camada	1	1	1

Na tabela, nota-se a utilização da função tangente hiperbólica como função de ativação da rede neural *backpropagation* tradicional e uma camada oculta (*hidden layer*) sobre os neurônios artificiais da rede então criada. Como função diferencial calculadora dos erros acumulados optou-se pelo uso da soma dos erros com penalização quadrática, visto que esta apresentou melhor taxa de convergência nos testes realizados e otimização com gradiente descendente. O objetivo da rede neural criada era classificar as entradas em positivo ou negativo de acordo com teste escolhido. Por exemplo, decidir se ou Euro iria

subir 1% em relação ao Dólar no instrumento negociado EURUSD, neste caso cabia à camada de *output* dos neurônios classificar de forma positiva (1) ou (0) de forma negativa o rótulo *Up* (subir). O mesmo seria válido para determinar a queda de 1% ou desvalorização do Euro frente ao Dólar (*Down*), prevendo-se o comportamento nos próximos cinco dias.

#### 4.1 Preparação dos Dados

Os dados originais continham as informações de valores de abertura, fechamento, valores máximo e mínimo negociados durante um minuto. O autor preferiu realizar seus estudos, por uma questão de tempo, limitando-os à comparação preditiva sobre dias e não horas ou minutos, com isso, conservou-se apenas os dados referentes a um dia de negociação, preservando-se o dia-a-dia e não minuto a minuto. Portanto, reduziu-se o número de observações da ordem de  $10^6$  para  $10^2$ , ou de milhão para mil observações compreendendo os 48 meses como sendo a base de dados definitiva para esta pesquisa. Para a construção do modelo, optou-se por construir um modelo preditivo classificatório de forma supervisionada, onde o rótulo ou *label* seria predizer sim ou não para um acréscimo (ou decréscimo) de 1% no preço corrente do instrumento EURUSD nos próximos sete dias. A escolha do prazo se deve ao fato da necessidade no curto prazo de poder-se determinar mínimas variações em um dado instrumento de negociação. Não se objetiva primariamente a exploração especulatória onde um *trader* busca ganhar em poucas horas com a variação do par negociado, porém em um prazo de aproximadamente uma semana poder indicar possíveis variações pensando-se no melhor momento para remessas de divisas ou vantagens de exploração cambial a empresas que de algum modo fazem uso do câmbio sem buscar lucros maiores nesta atividade como fim. Na escolha da dimensão deste modelo classificatório, algumas variáveis independentes ou *features* foram escolhidas com base na opinião do próprio pesquisador, *trader* e conhecedor do mercado de FOREX além de pesquisas e opiniões de outros pesquisadores quanto a relevância de certos indicadores (ABU-MOSTAFA e ATIYA, 1996; KUREMOTO et al., 2014). A Tabela 2 apresenta estas dimensões.

**Tabela 2. Dimensões utilizadas no modelo**

	Descrição
Valor máximo 24 horas atrás	Valor máximo registrado durante últimas 24 horas
Valor máximo 5 dias antes	Valor máximo registrado durante últimos 5 dias
Valor máximo 7 dias atrás	Valor máximo registrado durante últimos 7 dias
Valor mínimo 24 horas atrás	Valor mínimo registrado durante últimas 24 horas
Valor mínimo 5 dias antes	Valor mínimo registrado durante últimos 5 dias
Valor mínimo 7 dias atrás	Valor mínimo registrado durante últimos 7 dias
Valor SMA 20 dias	Valor do indicador SMA últimos 20 dias
Valor ADX 14 dias	Valor do indicador ADX últimos 14 dias

Tais *features* (dentro de um total de 1030 dias ou observações) se somaram a 8 (oito) dimensões no modelo final observadas na Tabela 2, aqui discutidas: foram tomados os valores mínimos e máximos assumidos pelo instrumento nos períodos de 1 dia, 5 dias e 7 dias anteriores ao momento no qual se faz a predição. O modelo  $f(x)$  busca determinar a maior taxa de acertos (com  $x$  tal que  $x_i$  em  $\{x_1, x_2, \dots, x_n\}$   $n = 1030$ .  $x_i$  em  $IR^8$ ). O

objetivo é prever se o instrumento aumenta seu valor (sobe) ou registra perda (desce) 1% nos próximos 7 dias. Também foram empregados como indicadores o *moving average* (MA) e o *average directional index* (ADX). O primeiro indicador, extensivamente utilizado entre *traders* de FOREX pode indicar uma mudança nos movimentos do mercado em um dado período, nesta pesquisa avaliou-se sobre o período de  $d = 21$  dias, já uma relação temporal diferente ( $d = 14$  dias) sendo observada para o ADX, sendo que este último visa indicar a direção da nova tendência aparentemente emergente. Dado  $f(x)$  resultando em previsões corretas para  $d$  dias, empiricamente (após muitos testes) concluiu-se que para o valor de  $d$  em dias, o valor que do hiper-parâmetro  $d$  que maximiza o resultado final de previsões corretas do modelo para ADX é dado por:

$$\underset{d}{\operatorname{argmax}}(f(x)) = 3 * d - 1 \quad (1)$$

Aqui se faz uma breve justificativa sobre a escolha do período e dos indicadores sendo contrastados como parte das *features* do modelo. Dada que a intenção final do modelo é a classificação de comportamento do instrumento EURUSD nos próximos 7 dias ( $d = 7$ ), interpretar os movimentos do mercado em um período  $2d$  dias pode trazer informações mais precisas sobre seu comportamento momentâneo, medida esta, empírica refinada após alguns testes realizados pelo próprio pesquisador. Para períodos maiores a relação parece se preservar, já o mesmo comportamento ainda não se demonstrou convergir para períodos muito curto de tempo, ou previsões no próprio *day trade* ou com menos de dois dias de análise, ainda que os estudos parecem indicar uma razoável possibilidade estatisticamente significativa de acurácia preditiva, ainda a ser verificada. A base de cálculo geralmente empregada nestes tipos de indicadores é apresentada a seguir:

$$u(d) = \frac{1}{D_1} + \sum_{i=D_1+1}^d x(i) - \frac{1}{D_2} + \sum_{i=D_2+1}^d x(i) , \quad (2)$$

Segundo Abu-Mostafa e Atiya (1996),  $x(d)$  é o preço do instrumento no dia  $d$ , e  $D_1$  e  $D_2$  ( $D_1 < D_2$ , e usualmente  $D_2 \sim D_1$ ) compreendem o tamanho da janela. O sinal de  $u(d)$  determina a tendência do preço do ativo, como subir ou descer. A presente pesquisa tem sua base de dados ancorada em dois dos mais utilizados indicadores por economistas e *traders* objetivando demonstrar a validade de modelos construídos sobre redes neurais e sua equivalência com outros modelos preditivos mais utilizados na literatura contemporânea (ABU-MOSTAFA e ATIYA, 1996). De tal forma, visando demonstrar tal equivalência estatística significativa do modelo e não meramente a construção do melhor modelo possível este estudo se concentrou em realizar uma boa previsão com resultados equivalentes ou talvez superiores aos melhores algoritmos da literatura extensivamente utilizados, porém com um fim teórico e demonstrativo; e aqui o pesquisador deixa claro que refinamentos e melhores resultados podem ser obtidos sobre este mesmo modelo através do uso de cuidadosas análises sobre hiper-parâmetros e escolha de indicadores e demais *features*. Com o intuito de manter a normalização requerida para o problema, as *features* ou preditores foram escalados adequadamente.

Conforme mencionado anteriormente, os 48 meses (1030 dias) compreendidos na pesquisa contém um período de crise econômica agravada pelas mudanças



macroeconômicas europeias e, portanto, exercendo forte pressão sobre o Euro frente ao Dólar, o que se observa pela grande queda no preço registrada desde o início do período, o que pode agravar o viés com uma forte tendência sobre os dados. Porém, tal distorção e pressão serve aos propósitos deste estudo uma vez que se pretende demonstrar a adequação de modelos preditivos de redes neurais ao desempenho real de séries financeiras no mercado considerando dados de análise técnica agregando-se a comportamentos de preço em um determinado período independente das crises, uma decisão deve ser tomada com um modelo que leve em conta variações ou pressões macroeconômicas exógenas ou fundamentalistas, ressalta-se que estas últimas não foram consideradas diretamente no modelo, porém suas consequências foram devidamente “aprendidas” pela rede neural.

## 4.2 Treinamento do Modelo

Dada a atenção recente feita por pesquisas em aprendizado de máquina atribuindo excelentes resultados ao *Random Forest* como algoritmo de predição favorito com melhor desempenho em séries temporais financeiras e FOREX (MONTGOMERY et al., 1990; ABU-MOSTAFA e ATIYA, 1996; DUNIS et al., 2010; THEOFILATOS et al., 2012), este estudo utilizou-o como a linha de base comparativa frente a três outros modelos MLP com *backpropagation*. Definiu-se as oito dimensões preditoras do modelo classificador o que incluía dados de variação nos valores máximos e mínimos registrados nos dias anteriores à predição bem como indicadores de movimento e tendência do mercado considerando as duas últimas semanas antes da realização da predição. Tal modelo foi treinado sobre o *Random Forest* e nos três algoritmos de MLP mencionados no início da sessão. Realizou-se validação cruzada (*cross-validation 10-fold*) sobre os 1030 dias coletados compreendendo o período de 1 de janeiro de 2013 a 31 de dezembro de 2016, sendo 70% dos dados utilizados para treinamento e 30% para teste em cada uma das 10 validações realizadas (DUNIS et al, 2010). Várias séries de divisão dos dados e teste foi realizada de forma aleatória durante os meses descritos pelo pesquisador, utilizando como ferramenta a linguagem R sobre o R Studio e suas bibliotecas no CRAN de *Machine Learning* e *Random Forest* (*neuralnet*, *RandomForest*). Vários treinamentos e resultados foram agrupados em 3 baterias de testes (*10-fold cross validation*) para cada um dos quatro algoritmos, totalizando 30 testes ao todo – desconsiderando os testes que falharam<sup>1</sup> em convergir para cada um dos modelos de redes neurais eventualmente.

## 5. Discussão dos resultados

Os resultados com validação cruzada realizados com 10 subconjuntos dos dados, feitos em 3 séries estão incluídos nesta análise, na Tabela 2 são apresentadas as médias dos respectivos testes. Foram consideradas condições semelhantes com pequenas variações nos hiper-parâmetros dos algoritmos de aprendizado de máquina executados. Nas redes neurais, utilizou-se 2 camadas ocultas para a rede criada sobre *backpropagation* com taxa de aprendizado auto calculada pela API e 1 camada oculta (*hidden layer*) para as outras duas, segundo Tabela 1. Nota-se conforme esperado que os testes classificando queda de 1% durante os próximos 7 dias apresentam pior desempenho em comparação

---

<sup>1</sup> Em caso de falhas na convergência do gradiente descendente, uma nova tentativa era feita sobre os dados até convergência nos parâmetros esperados.

com o teste da classificação de aumento de 1% sobre o par estudado. Isto se justifica pelo viés introduzindo no ano de 2014, quando da queda acentuada levando a taxas baixas no preço negociado do instrumento. Pode-se concluir que mesmo em condições adversas o modelo de redes neurais tende a preservar uma boa predição ou pelo menos estatisticamente assumir resultados o mais próximo possível da realidade considerando apenas fatores endógenos ao modelo conjugando análise técnica e variação no médio termo. As porcentagens apresentadas na Tabela 3 indicam as médias percentuais de acerto sobre o total de casos testados por algoritmo e seus respectivos desvios padrões (entre parênteses) ao final de 30 iterações, ou 3 *cross-validations 10-fold*.

**Tabela 3. Comparativo entre resultados apresentados (acurácia) após 30 iterações**

	Random Forest	Backpropagation Tradicional (BKPROP)	Backpropagation com pesos e backtracking (ativ = tanh) (RPROP)	Backpropagation com auto calc. taxa aprendizado (SAG)
Subir 1%	77,8% (11,5%)	75,4% (3,21%)	76,6% (3,38%)	74,8% (3,72%)
Descer 1%	71,2% (15,4%)	67,7% (4,2%)	69,8% (4,03%)	66,3% (4,59%)

Os dados da Tabela 3 apontam boas performances para os três algoritmos de redes neurais e para a linha de base (*Random Forest*). Isto se aplica tanto prevendo alta ou baixa do instrumento de estudo. Para confirmação da equivalência estatística fez-se uso da Análise de Variância (ANOVA) sobre os grupos de algoritmos, com intervalo de confiança de 95% ( $\alpha = 5\%$ ). Confirmando-se os testes de permissa (normalidade, homoscedasticidade e independência dos dados), então empregou-se o teste de *Tukey* (HSU, 1996). O resultado deste teste é apresentado na tabela seguinte e seus *p-values* discutidos na sequência:

**Tabela 4. Comparativo entre resultados do teste de Turkey**

Tukey multiple comparisons of means 95% family-wise confidence level				
Fit: aov(formula = Acuracia ~ Algoritmo + Problema, data = data)				
\$Algoritmo	diff	lwr	upr	p adj
BKPROP-RFOREST	-3.455	-5.7710488	-1.1389512	0.0166501
RPROP-RFOREST	-1.820	-4.1360488	0.4960488	0.0926811
SAG-RFOREST	-4.490	-6.8060488	-2.1739512	0.0078547
RPROP-BKPROP	1.635	-0.6810488	3.9510488	0.1200410
SAG-BKPROP	-1.035	-3.3510488	1.2810488	0.3110338
SAG-RPROP	-2.670	-4.9860488	-0.3539512	0.0341138

Dado que para os três algoritmos (BKPROP, RPROP e SAG) o teste ANOVA sobre RFOREST apresenta *p-value* como 0.012, 0.067 e 0.005 respectivamente, rejeitando a hipótese nula de igualdade de desempenho<sup>2</sup>. Na Tabela 4 observa-se as múltiplas comparações dos resultados obtidos e pode-se verificar que a falta de evidências nos resultados para rejeição da equivalência permite a este estudo concluir que algoritmos de redes neurais podem obter desempenhos equivalentes aos de algoritmos de aprendizado de máquina consagrados no uso de séries temporais financeiras como o *Random Forest* (SOUZA et al., 2014).

<sup>2</sup> Nota-se que para níveis de significância do ANOVA de  $\alpha = 0.05$  esta relação se preserva tanto para o RPROP (com melhor desempenho), quanto para os demais algoritmos que comprovam sua validade.

## 6. Considerações finais

O estudo se mostrou favorável à utilização de aprendizado de máquina na predição de séries temporais, em especial atenção ao uso de redes neurais. Com performance muito semelhantes ao *Random Forest*, um dos mais estabelecidos e confiáveis algoritmos referenciados na literatura para *forecasting* de séries temporais econômicas. A capacidade do modelo em efetuar classificações próximas à realidade mesmo em frente a crises detectadas e consequente introdução de possíveis vieses se somam aos fatores positivos da utilização de redes neurais na predição de séries financeiras de FOREX.

Enfatizamos que melhorias e refinamentos podem ser feitos sobre o modelo preditivo, além da adição de dimensões significativas, uma vez que apenas dois dos principais indicadores foram considerados na construção deste modelo a título de estudo e justificativa da obtenção de resultados. Para efeitos deste estudo não se considerou nenhuma análise fundamental, o que definitivamente melhoraria o desempenho do modelo e por certo pode ser considerado na construção de melhores modelos preditivos incluindo para geração de modelos de *Quantitative Trading*, onde *machine learning* aliado a diferentes análises se mostra eficaz. Cabe-se nesta análise mencionar o par EURUSD, que no ano de 2014 vivenciou uma grande turbulência e forte pressão de baixa devido a problemas e instabilidade nos países componentes do Euro, em especial a Grécia e Portugal, levando mesmo a conjecturas do rompimento da moeda então forte. Tal impacto fundamentalista não será considerado nas análises deste estudo, ainda que este faz suas considerações levando-se em conta o desempenho de redes neurais mesmo em condições econômicas particulares.

Também se notou que durante os testes com números maiores de neurônios nas redes a taxa de erro aumentava, e diferentes funções de ativação e minimização de erro podem produzir resultados melhores. Esta última consideração ainda que possa parecer não favorecer o uso de redes neurais profundas, *deep learning* (DL) para classificação de séries financeiras, tal prerrogativa deve ser melhor revisada em trabalhos futuros e possivelmente novos modelos de indicadores e dados como preditores podem favorecer redes mais complexas e não lineares. Provavelmente o modelo aqui estudado como classificador talvez não seja complexo o suficiente para DL e redes profundas. Novos testes com DL foram realizados pelo autor e bem-sucedidos, porém fogem ao escopo desta análise e poderão porventura se tornar objeto de estudo futuro. Existem ainda outras áreas não exploradas neste estudo, como a busca em diminuir o rebaixamento máximo (*drawdown*) do mercado quando em posições desfavoráveis, preocupação constante do *trader*, outras podem incluir refinar os intervalos considerados para cada indicador, bem como otimizar o tempo máximo no qual se deseja prever os resultados. Ainda que o objetivo não seja procurar o melhor modelo preditivo para uso em séries construídas sobre o FOREX (em especial com o par EURUSD), este estudo foi capaz de conduzir uma intensa pesquisa e produzir resultados a favor de demonstrar a equivalência do uso de redes neurais se comparado a modelos clássicos apresentando bons resultados mencionados na literatura sobre séries financeiras. Deste modo, a presente análise cumpriu com seus objetivos de demonstrar a eficácia na utilização de redes neurais em séries temporais financeiras.

## 7. Referências

ABU-MOSTAFA, YASER S.; ATIYA, AMIR F. **Introduction to Financial Forecasting: Applied Intelligence** 6. Manufactured in The Netherlands, 205-213, Kluwer Academic Publishers, 1996.

- BERLINGER, Edina et al. **Mastering R for Quantitative Finance**. Birmingham, Mumbai: Packt Publishing, 2015.
- BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. **Time Series Analysis**. Prentice Hall, 1994.
- BREIMAN, Leo. **Random Forests**. Statistics Department, University of California, Berkeley, CA 94720: 2001.
- CHAPPELIER, J. C.; GRUMBACH, A. **Time in Neural Networks**, in SIGART BULLETIN. ACM Press, 5(3), 1994.
- DUNIS, C.; WILLIAMS, M. **Modeling and trading the Euro/Us Dollar exchange rate: do neural networks perform better?**, Derivatives Use, Trading and Regulation, Vol. 8, No. 3, p. 211-240, 2002.
- DUNIS, C.; LAWS, J.; SERMPINIS, G. **Modelling and trading the EUR/USD exchange rate at the ECB fixing**. The European Journal of Finance, Vol. 16, No. 6, p. 641-561, 2010.
- GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 4. ed. São Paulo: Atlas, 2008.
- HSU, J. **Multiple comparisons: theory and methods**. CRC Press, 1996.
- JOHNSON, R. A.; WICHERN, D. W. **Applied multivariate statistical analysis**. Fourth Edition. New Jersey: Prentice Hall, 1998.
- KAUFMAN, E. **The New Commodity Trading Systems and Methods**. John Wiley & Sons, 1987.
- KUREMOTO, Takashi; KIMURA, Shinsuke; KOBAYASHI, Kunikazu; OBAYASHI, Masanao. **Time Series Forecasting Using a Deep Belief Network with Restricted Boltzmann Machines**. Neurocomputing, ELSEVIER, 137, p. 47-56, 2014.
- MALKIEL, B. A. **Random Walk Down Wall Street**. New York: W.W. Norton & Co., 1985.
- MARCONI, Marina de Andrade; LAKATOS, Eva Maria. **Metodologia científica**. 5 ed. São Paulo: Atlas, 2007.
- MONTGOMERY, D.; JOHNSON, L.; GARDINER, J. **Forecasting and Time Series Analysis**. McGraw-Hill Inc., 1990.
- ROSENBLATT, Frank. **Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms**. Spartan Books, Washington DC, 1961.
- RIEDMILLER, M. **Rprop - Description and Implementation Details**. Technical Report. University of Karlsruhe, 1994.
- RIEDMILLER, M.; BRAUN, H. **A direct adaptive method for faster backpropagation learning: The RPROP algorithm**. Proceedings of the IEEE International Conference on Neural Networks (ICNN), pages 586-591. San Francisco, 1993.
- SELLTIZ, C.; WRIGHTSMAN, L. S.; COOK, S. W. **Métodos de pesquisa das relações sociais**. São Paulo: Herder, 1965.
- SOUZA, Paulo V. C.; TORRES, Luiz C. B.; BRAGA, Antônio P.; COELHO, Frederico G. F. **Análise de algoritmos de maximização de margem baseados em grafos de gabriel e fecho afim**. Anais do XX Congresso Brasileiro de Automática, Belo Horizonte, MG, 20 a 24 de setembro de 2014.
- THEOFILATOS, Konstantinos; LIKOTHANASSIS, Spiros; KARATHANASOPOULOS, Andreas. **Modeling and Trading the EUR/USD Exchange Rate Using Machine Learning Techniques**. ETASR - Engineering, Technology & Applied Science Research, Vol. 2, No. 5, 269-272, 2012.
- ULBRICHT C. **State Formation in Neural Networks for Handling Temporal Information**. Institut fuer Med.Kybernetik u. AI, Univ. Vienna, 1995.
- ULLRICH, C.; SEESE, D.; CHALUP, S. **Foreign exchange trading with support vector machines**. Advances in Data Analysis: Studies in Classification, Data Analysis and Knowledge Organization, Part VII, pp. 539-546, 2007.